A 北京邮电大学人工智能学院

本科毕业设计（论文）开题报告

学院	人工智能学院		专业	人工智能	
学生姓名	邓圣曦	学号	2022212222	班级	2022219112
指导教师姓名	刘刚	所在单位	北京邮电大学 人工智能学院	职称	副教授
设计（论文）题目	（中文）基于文本描述的零样本语音合成研究				
	（英文）Research on Text-Description-Based Zero-Shot Speech Synthesis				

一、 选题的背景和意义

近年来，随着深度学习技术的飞速迭代，特别是以 ChatGPT 为代表的大语言模型（Large Language Models, LLMs）和生成式人工智能（AIGC）技术的爆发式增长，人机交互方式（HCI）正经历着从单一模态向多模态融合的深刻变革。作为人机交互的经典应用之一，在这场变革中，智能语音合成（Text-to-Speech, TTS）技术已不再局限于传统机械的“给定文本朗读文字”，而是向着“高表现力、高可控性、零样本克隆”的生成式语音方向演进。语音合成技术已从解决“能不能听得懂”的清晰度问题的阶段，发展到了解决“听起来像不像真人”的自然度与情感表达问题的阶段。

零样本语音合成（Zero-Shot TTS）是指仅需给定目标说话人极短（通常 3-10 秒）的参考音频作为推理阶段的声学提示（Acoustic Prompt），用于来引导模型复刻音色与韵律，即可在全程无需对模型参数进行任何微调或梯度更新的情况下实时合成出具备该说话人音色与韵律风格的高质量语音。该技术范式区别于传统的通常需要数小时录音数据的微调/训练合成方案,展现出了更强的易用性，降低了使用门槛。

在零样本语音合成领域，基于神经编解码语言模型（Neural Codec Language Models）的架构已成为当前的主流范式。自 2023 年微软推出 VALL-E 以来，该类模型通过将语音波形离散化为声学 Token，并利用自回归或非自回归语言模型进行预测，实现了强大的上下文学习能力。后续的 NaturalSpeech 3（2024）、Fun-CosyVoice3（2025）等工作进一步优化了这一架构，仅需约 3 秒的参考音频即可在零样本条件下克隆目标说话人的音色、韵律及声学环境，评测指标接近甚至超过真人水平。该技术不仅对未见说话人具备出色的泛化能力，展现出“千人千面”的生成多样性，还在跨语种的音色克隆与风格迁移等场景下表现突出。然而在实际应用中这项技术依旧存在着一些痛点与局限性：

- 在实际的创意内容生产（如有声小说制作、游戏 NPC 配音、影视行业后期）中，“需要参考音频”本身就会是一个的痛点。很多时候，用户希望生成一个全新的、现实中不存在的角色声音（如“一个来自未来的赛博废土风格机器人”这种人设），此时无法提供现成的参考录音。如果使用真实人物的录音进行克隆，由于相关法律法规目前仍不够明确完善，会存在版权争议风险和潜在的滥用隐患。
- 特征解耦困难： 受录音条件等现实情况影响，参考音频往往携带了与其说话人身份无关的冗余信息，如背景噪声、特定的瞬时情绪乃至感冒等的影响。现有的模型往往难以将“音色”与“环境/情感”完全解耦，在 few-shot 的场景下，这些无关干扰因素的影响往往会被放大，导致合成语音中出现隐隐约约的电音、吞字多字错字或不符合当前文本语境的情感泄漏问题。

- 泛化能力存在边界： 仅凭一段音频很难精确充分地控制生成的风格。例如，用户很难仅提供一段平静的参考音频，然后要求模型生成一段“歇斯底里”的语音，因为参考音频中缺乏对应的高频声学特征。

虽然 ChatTTS 等对话模型效果出色，但当前必须必须要提供参考音频作为声音参考。在小说等文字创作内容中，只有文本形式的人设，并没有直接的参考音频。这成为了因此，“如何将自然语言的语义描述精准映射到 TTS 模型的声纹空间”是本课题要解决的核心问题。

二、 研究的基本内容

内容一： 综述零样本、对话式语音合成发展现状，复现一个成熟的零样本对话式合成系统

零样本语音合成技术的发展经历了从传统的声学特征回归向基于离散编码的语言建模范式的重大转变。以 VALL-E 为代表的神经编解码语言模型开创了将 TTS 视为条件语言建模任务的先河。该类方法利用神经音频编解码器将连续波形离散化为 Token 序列，通过在大规模数据上进行自回归（Auto-Regressive）预训练，涌现出了强大的上下文学习（In-Context Learning）能力，仅需 3 秒参考音频即可实现零样本克隆。这类算法的优势在于极强的泛化能力和对说话人音色的快速适应，但缺点是自回归生成过程容易出现重复、丢词、吐字不清等鲁棒性问题，且难以对韵律进行细粒度控制。

为了解决生成质量与属性解耦的矛盾，出现了以 NaturalSpeech 3 为代表的非自回归扩散生成模型。该类算法通过设计分解式神经编解码器（如 FACodec），通过压缩维度/有监督学习/梯度反向传播/drop 等流程设计，成功将复杂的语音信号解耦为持续时长、内容、韵律、声学细节等独立子空间，并利用扩散模型（Diffusion Models）在各个子空间内进行“分而治之”的建模生成。相比于语言模型范式，分解式扩散模型在语音质量、相似度及推理稳定性上表现更优，但模型架构更为复杂。

此外，针对仅依赖音频提示（Audio Prompt）存在的局限性，基于自然语言提示（Prompt-based）的语音生成与编辑成为了一个热点方向。Step-Audio-EditX、PromptTTS++等工作不再局限于单一的音频参考，而是探索利用自然语言描述（如“悲伤的语气”、“沙哑的声音”）来显式控制语音风格。这类方法通过构建文本描述与声学特征的跨模态映射机制，结合预训练语言模型&大语言模型的语义理解能力，实现了更直观、灵活的语音编辑与生成。我们将通过对上述三种主流技术路线的学习与思考，梳理出零样本语音合成的技术演进脉络，重点掌握离散 Token 处理与多模态特征对齐的核心机制，为后续构建支持文本描述控制的对话式语音合成系统奠定理论与技术基础。

选取 ChatTTS 作为本研究的基座模型。该框架开源了在 4 万小时数据上进行无监督微调的预训练模型，并针对对话式任务进行了优化，原生支持多说话人混流合成及细粒度韵律控制（如笑声、停顿）。安装依赖配置计算环境，复现 ChatTTS 的推理流程，并通过客观指标（WER, SECS）和主观听感测试（MOS）验证其在零样本音频提示场景下的性能基线。

本内容对毕业要求指标点的支撑：

- 通过查阅国内外关于零样本语音合成及对话式语音生成的相关文献，调研现有技术路线，明确研究背景与现状，支撑了指标点 4.1
- 通过学习深度学习开发环境及现代语音合成开源工具与框架，掌握复现现有成熟系统所需的工具与技能，支撑了指标点 5.1
- 在复现过程中，通过自主查阅技术文档和社区交流解决环境配置及代码运行中的问题，培养自主学习与解决未知问题的能力，支撑了指标点 12.1

支撑毕业要求指标点：

☐2.1 ☐2.2 ☐2.3 ☐4.1 ☐5.1 ☐5.2 ☑6.2 ☑7.1 ☑10.1 ☑11.2 ☐12.1

内容二： 根据长文本（剧本或小说）研究如何生成人物角色的文本描述（显性描述），

需要具有良好的角色（说话人）定义和区分能力，研究重点在于说话人的文本描述（定义）规范，可人工完成或模型生成；设计并实现一个从显性（文本）描述到隐性（embedding）描述的适配器（或多模态对齐模块），可以是无中生有的虚拟说话人，或者是大规模说话人数据集中的某个人物。

这部分是本课题的核心算法研究内容，主要针对长文本场景下角色声音画像提取难的问题和如何实现从文本直接映射到声音特征的研究：

（1） 基座模型声纹潜空间分析与语义映射规律研究:

针对“文本描述控制语音”的理论可行性，研究基座模型在预训练过程中形成的说话人嵌入（）Speaker Embedding）空间的分布特性。利用 t-SNE 等降维可视化手段，尝试找出不同性别、年龄、音色及情感等属性在几何空间中的聚类关系 。通过在 LibriTTS-P 等带有自然语言标注的数据集上进行关联性分析，验证该潜空间是否具备语义可解释性，并量化文本描述语义与声学特征之间的映射强度，为适配器的架构设计提供理论依据。

LibriTTS-P 是一个基于高质量英语语料库 LibriTTS-R 构建的新型数据集，旨在支持基于提示词的可控语音合成和说话风格字幕生成任务。该数据集包括 2,443 名说话人，总计包含 373,868 条提示词。其特点在于一方面包括手动标注捕捉人类对说话人身份特征感知的“说话人提示词”；另一方面通过分析音频统计数据并结合大语言模型增强，自动生成涵盖音高、语速和音量的“风格提示词”。

鉴于 LibriTTS-P 为纯英语数据集，本阶段拟参考其混合标注方法，利用 LLM 对中文有声书等资源进行风格属性抽取，作为数据集补充，优化跨语言的特征对齐表现。

（2） 基于描述文本驱动的跨模态语义映射机制建立：

研究建立从显性自然语言描述到隐性声学特征的映射机制。核心任务是探究如何将抽象的文字化描述准确转化为语音合成模型可识别的声纹特征向量 。如何通过跨模态对齐，确保在无参考音频的零样本场景下，生成的虚拟音色与文本描述保持高度的语义一致性；如何利用预训练语义空间的先验知识，提升系统对训练集中未出现过的新描述词的泛化能力；都是需要解决的问题。

本内容对毕业要求指标点的支撑：

- 定义说话人的显性文本描述规范，将抽象角色特征转化为计算机可处理的表达形式，支撑了指标点 2.1
- 分析从文本描述到声学特征的映射机制，设计合理的适配器网络结构及多模态对齐算法，以解决跨模态特征融合问题，支撑了指标点 2.3
- 熟练运用现代深度学习工具和计算资源，对设计的数据集构建管线和适配器模型进行训练、调试与验证，支撑了指标点 5.2

支撑毕业要求指标点：

☑2.1 ☑2.2 ☑2.3 ☐4.1 ☐5.1 ☑5.2 ☐6.2 ☐7.1 ☐10.1 ☐11.2 ☐12.1

内容三：实现一个多角色有声小说自动生成演示系统，并进行性能评价和优化

本部分任务是将前述核心算法研究成果进行工程化落地，构建一个能够端到端运行的多角色有声小说自动生成演示系统。尝试通过集成基于 Agent 的文本解析模块，解决长篇文学作品中因 Token 数量巨大导致的说话人身份追踪难题与长程人设依赖遗忘问题。该模块将自动从字里行间解析角色的显性特征与动态情感，转化为符合课题规范的细粒度文本描述流，并以此驱动内容二所设计的跨模态适配器实时产生精确的说话人嵌入向量，从而指引对话式语音合成基座模型生成具备音色一致性与自然韵律的多角色语音。

在系统架构的实施过程中，设计将深度整合 AIGC 相关伦理准则，防范非法声音克隆与版权滥用。并针对长文本生成的实时性需求，探索推理流程的并行化与性能优化方案，以构建一个兼具技术前瞻性与实际工程应用价值的集成演示系统。

本内容对毕业要求指标点的支撑：

- 在系统设计与评价中，充分考虑 AIGC 生成内容的伦理责任，分析并防范声音克隆可能带来的版权与安全风险，支撑了指标点 6.2
- 在模型优化阶段，考虑优化算法的计算效率与资源消耗，符合绿色计算和可持续发展的政策导向，支撑了指标点 7.1
- 对实验数据（如 MOS 评分、相似度等）进行整理与图表化展示，撰写逻辑清晰的毕业设计论文，准确表达研究成果，支撑了指标点 10.1
- 综合运用软件工程方法，完成从模块开发到系统集成的全过程，构建功能完整的演示系统，体现项目管理与实践能力，支撑了指标点 11.2

支撑毕业要求指标点：

□2.1 □2.2 □2.3 □4.1 □5.1 □5.2 ☑6.2 ☑7.1 ☑10.1 ☑11.2 □12.1

三、 拟解决的主要问题

（1） 跨模态语义到声学特征的精准映射与解耦

自然语言对声音的描述（如“沧桑”、“阴郁”）往往是抽象且高维的，而语音合成模型需要的声学特征是具体的、低维、数字描述的物理特征。如何建立一个有效的映射机制，在确保声学潜空间具备语义可解释性的前提下，将 RoBERTa 提取的高维语义特征精准转化为 ChatTTS 识别的声学向量，是本课题的首要难题。此外，还需攻克在零样本场景下，如何利用对比学习等手段实现特征解耦，确保生成的语音在满足文本描述特征的同时，不产生非目标属性的“情感泄漏”或音质降级。

（2） 高质量细粒度“文本描述-语音”对齐数据的稀缺与跨语言对齐

构建能够理解自然语言描述的 TTS 模型极度依赖精细化的标注数据。虽然已有 LibriTTS-P 这一包含丰富对齐提示词的高质量数据集，但其纯英语的特性导致了跨语言零样本合成的潜在问题。如何在缺乏大规模中文对齐语料的情况下，借鉴 LibriTTS-P 的混合标注（Hybrid Annotation）逻辑，我们可能需要利用 LLM 与自动化 ASR 工具高效构建并清洗出一套包含中文角色人设与风格描述的数据集，并实现中英语义特征在声学空间中的统一对齐。

（3） 长文本场景下的角色一致性与情感连贯性

如何构建高效的双层记忆机制与状态变化检测架构，以在有限的上下文窗口内，能敏锐捕捉“动态状态（如突发情绪、生理变化）”的瞬时突变。同时，需解决 Agent 在复杂行文逻辑下可能产生的特征提取幻觉问题，确保生成的动态 Prompt 流（Dynamic Prompt Flow）准确反映原著场景，实现长文本理解与语音生成控制的无缝衔接。另外考虑到文学写作中可能会有伏笔/反转等手法存在，为了更准确的描述情绪，可能需要引入修补回溯前文的 prompt 的能力。

四、 研究方法和措施

根据本课题研究的基本内容和拟解决的主要问题，主要采用以下方法进行研究：

（1） 文献查找及阅读：

利用 arXiv、IEEE Xplore、ACL 等学术数据库，系统查阅近年来关于零样本语音合成、语音风格化编辑、大语言模型在语音中的应用以及跨模态表征学习等的重要标志性成果与最新论文。重点研究 NaturalSpeech 3、Step-Audio-EditX、PromptTTS++ 等论文的开源代码与技术报告，深入理解其隐式描述构建的逻辑，文本-音频映射实现方法，为后续的算法设计与改进奠定理论基础。

（2） 性能评估基准

复现 ChatTTS 基座模型后对各项评估指标进行测试，建立本课题的实验基线，以确保后续适配器改进效果的客观性与对比性。

自动化评价：利用 WER（字错误率）检测合成语音的转录准确度，采用 SECS（说话人相似度

余弦得分)计算适配器生成的 Embedding 与对应真实音色向量的匹配程度。同时应用 InstructTTSEval 基准，评估系统对复杂、长文本提示指令的遵循精度，检验引入 BERT 系预训练语言模型对文本描述泛化能力的提升有效性。

主观听测：组织基于 MOS（平均意见得分）的人类主观测试体系。分别针对音频的自然度（Naturalness）与提示一致性（Prompt-Audio Consistency）进行评测，验证用户在输入自由文本描述时，系统生成的音色是否符合人类感官对该描述的直观预期，以此论证本课题所设计的适配器的有效性。

（3） 算法设计与实验验证：

a. 基座模型声纹潜空间的拓扑分析与语义映射规律探析

i. 特征提取与语义关联分析：利用复现的 ChatTTS 基座模型，将数据集内的大规模音频样本输入其神经音频编解码器前端，在模型 Bottleneck Layer 捕获连续说话人嵌入（Speaker Embedding）或离散声学 Token 序列，获取代表音色与韵律等的高维特征向量 。同步提取数据集中配套的“说话人提示词”与“风格提示词”，通过计算性别、音高、语速等属性标签在声学空间中的互信息与聚类指标，量化语义标签与声学特征之间的关联强度。

ii. 拓扑分布与聚类可视化：利用 t-SNE 或 UMAP 等非线性降维算法，将上述高维瓶颈层特征投影至低维流形空间。通过观察 LibriTTS-P 中具有相同语义属性（如“成熟男性”、“沙哑音色”）的样本在空间中的几何聚类关系，验证潜空间的语义可解释性，从而为后续适配器的非线性映射设计提供理论依据与先验约束。

b. 基于语义向量映射的跨模态适配器设计与训练方案

i. 数据对构建：文本模态数据使用预训练 RoBERTa 作为文本模态的语义编码器，输入数据集中的专家标注提示词提取其语义特征向量，优化遇到训练集中未出现过的新描述词时的表现效果，提高泛化能力；音频模态数据则通过将对应音频输入 ChatTTS 基座模型提取其内部说话人嵌入获得，从而构建“文本描述-声学向量”的监督对，随后划分训练集/验证集/测试集。

ii. 适配器架构设计：适配器作为跨模态桥梁，其设计将充分参考 a 中通过降维可视化分析等步骤发现的聚类规律。预计适配器将采用多层感知机&transformer 结构设计。

iii. 训练策略与泛化：训练目标是最小化适配器预测向量与 ChatTTS 提取向量之间的距离。通过引入对比学习中的 InfoNCE 损失等训练方法，确保语义相近的描述能映射到声学空间中相近的聚类区域。借助预训练语言模型强大的语义抽象能力，使系统不仅能识别数据集内的固定标签，还能对未见的自由文本提示进行语义相似度外推，实现灵活的音色控制。

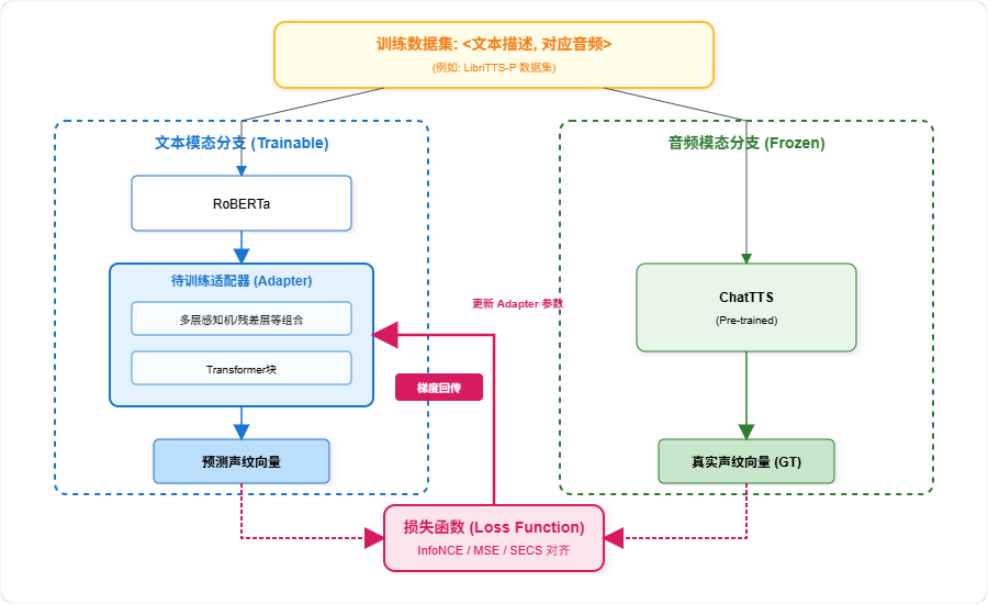

（4） 多角色有声小说生成自动演示系统构建

a. 基于 Agent 与 RAG 的层级化文本处理架构

构建一个动态维护的角色人设库来实现长程记忆管理。在预处理阶段利用 Agent 全文扫描并提取各角色的静态身份属性（如性别、年龄），并将其向量化后存储于检索增强生成（RAG）系统的向量数据库中，形成角色的持久化人设档案。

在实时生成环节，部署轻量化小语言模型（SLM）作为前置语义检测工具，对当前文本块进行滑动窗口式监测，如果检测到特定说话人登场或语境发生显著波动，触发检索机制，从 RAG 库中召回该角色的全局人设标签 。随后，；利用大语言模型将这些召回的“静态身份特征”与从当前剧情中实时推理出的动态情感状态（如突发怒火、低声耳语）进行上下文融合，生成具备角色一致性且符合适配器输入规范的文本描述流。确保了同一角色在不同章节间的音色稳定性的同时，赋予了合成系统敏锐的情感捕捉与表达能力。

b. 语音生成流程集成

将 Agent 生成的动态文本描述实时输入至内容二中开发的跨模态适配器，通过 RoBERTa 语义特征提取与残差映射网络，获取精确的说话人嵌入向量（Speaker Embedding）。随后，将该向量作为声学提示动态注入 ChatTTS 的推理生成管线，并配合细粒度韵律控制标签，获得自然的语音合成输出。

c. 模块化工程封装

按照模块化软件设计思想，将长文本解析引擎、跨模态适配器网络与语音合成基座进行集成。利用 Gradio 或 Vue 搭建可视化交互界面，支持剧本自动解析、角色特征预览/编辑修改及合成进度显示/音频播放等功能。

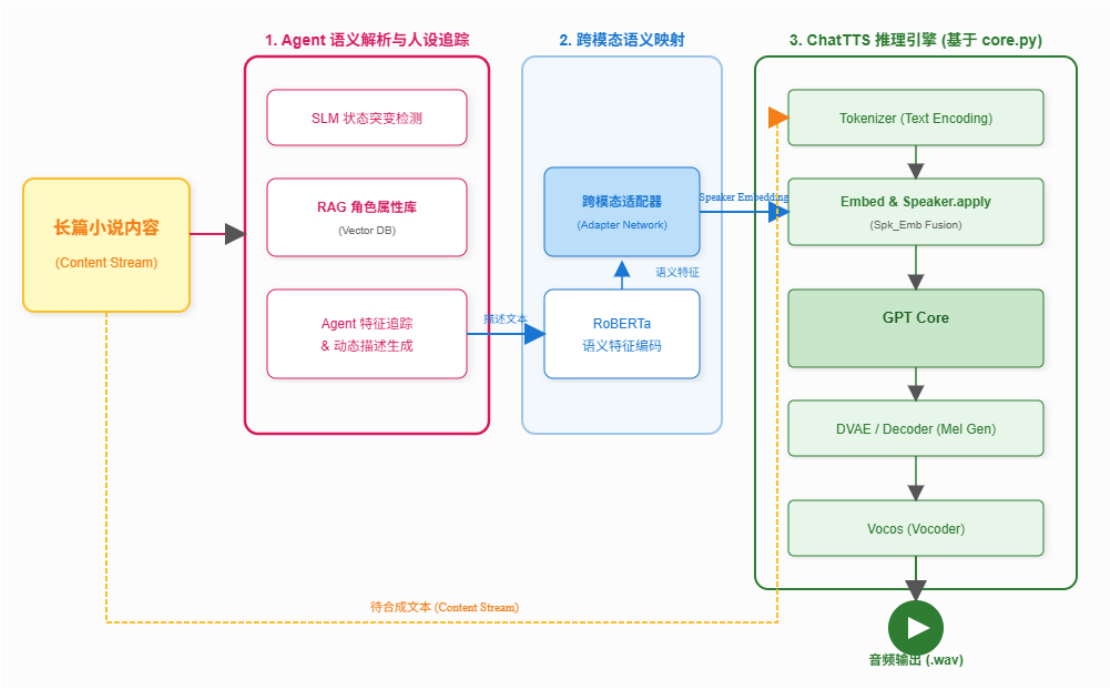

（5） 提出问题及讨论：

在进行毕业设计时，大概率会遇到风格控制效果不及预期、情感提取效果不理想或基层工具 bug 等工程问题。当经过一段时间的独立思考与调试仍无法解决时，将积极主动地请教指导老师与实验室师兄师姐，参与开源社区的讨论，通过多渠道交流获取解决方案，确保证研究工作的顺利推进。

五、 研究工作的步骤与进度

进度安排：

第 1 阶段(2025.12.01-2025.12.28)[秋季学期第 13-16 周]：确定研究方向，查阅 Prompt-basedTTS 及大模型相关文献，特别是 MultiActor-Audiobook 和 Step-Audio-EditX 等技术报告。调研文本描述控制语音的现状，完成文献综述，撰写并提交《开题报告》。

第 2-1 阶段(2025.12.29-2026.01.11)[秋季学期第 17-18 周]：搭建深度学习开发环境（配置 GPU 服务器、CUDA 环境等），学习 ChatTTS 等开源框架。复现成熟的零样本对话式语音合成系统，跑通推理流程，理解模型架构及数据处理流程。

第 2-2 阶段(2026.01.12-2026.01.25)[秋季学期第 19-20 周]：测试基座模型的性能指标，为后续训练优化建立基线。对基座模型声纹潜空间进行分析，总结归纳规律。

第 3 阶段(2026.03.02-2026.03.15)[春季学期第 1-2 周]：聚焦任务内容 2，利用 LLM 构建长文本中的角色定义规范。设计并实现“显性文本描述到隐性说话人 Embedding”的适配器/对齐模块。准备实验数据，进行初步的模型训练。

第 4 阶段(2026.03.16-2026.03.29) [春季学期第 3-4 周]：整理前期实验数据，评估适配器性能，撰写中期报告。参加学院组织的中期检查，展示初步的语音生成 Demo（如通过文字描述生成特定音色），根据专家反馈调整后续算法优化路线。

第 5 阶段(2026.03.30-2026.04.26)[春季学期第 5-8 周]：完成任务内容 3，将核心算法集成，搭建多角色有声小说自动生成演示系统。对系统进行综合性能评价（使用 InstructTTSEval 进行客观评测，并组织小规模 MOS 主观评测），针对推理速度进行优化。

第 6 阶段(2026.04.27-2026.05.17)[春季学期第 9-11 周]：整理全过程研究成果，进行实验数据图表化。完成毕业设计论文的撰写与排版。提交论文进行院级内审和查重检测，根据查重报告修改论文直至符合要求。

第 7 阶段(2026.05.18-2026.06.14)[春季学期第 12-15 周]：制作答辩 PPT，准备演示系统视频或现场演示环境。参加毕业设计答辩，根据答辩专家意见进行论文最终修改（定稿）。

目前的完成状态：

了解了课题目标及内容，确立研究方向。查阅语音合成领域相关资料，对任务实现路径有初步构想，完成开题报告。学习零样本合成相关知识，熟悉对话式合成系统的基本原理和工作框架。

六、 主要参考文献

[1] Wang C, Chen S, Wu Y, et al. Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers[J]. arXiv preprint arXiv:2301.02111v1, 2023.

[2] Ju Z, Wang Y, Shen K, et al. NaturalSpeech 3: Zero-Shot Speech Synthesis with Factorized Codec and Diffusion Models[J]. arXiv preprint arXiv:2403.03100v3, 2024.

[3] Xie T, Rong Y, Zhang P, et al. Towards Controllable Speech Synthesis in the Era of Large Language Models: A Systematic Survey[J]. arXiv preprint arXiv:2412.06602v3, 2024.

[4] Park K, Joo S, Jung K. MultiActor-Audiobook: Zero-Shot Audiobook Generation with Faces and Voices of Multiple Speakers[J]. arXiv preprint arXiv:2505.13082v1, 2025.

[5] Shimizu R, Yamamoto R, Kawamura M, et al. PromptTTS++: Controlling Speaker Identity in Prompt-Based Text-to-Speech Using Natural Language Descriptions[J]. arXiv preprint arXiv:2309.08140v2, 2023.

[6] Huang K, Tu Q, Fan L, et al. InstructTTSEval: Benchmarking Complex Natural-Language Instruction Following in Text-to-Speech Systems[J]. arXiv preprint arXiv:2506.16381v1, 2025.

[7] Yan C, Wu B, Yang P, et al. Step-Audio-EditX Technical Report[J]. arXiv preprint arXiv:2511.03601v2, 2025.

[8] Li Y, Han C, Raghavan V, et al. StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models[J]. arXiv preprint

arXiv:2306.07691v2, 2023.
[9] Liu A, Jin S, Lai C, et al. Cross-Modal Discrete Representation Learning[J]. arXiv preprint arXiv:2106.05438v1, 2021.
[10] Anastassiou P, Chen J, Chen J, et al. Seed-TTS: A Family of High-Quality Versatile Speech Generation Models[J]. arXiv preprint arXiv:2406.02430v1, 2024.
[11] Kawamura M, Yamamoto R, Shirahata Y, et al. LibriTTS-P: A Corpus with Speaking Style and Speaker Identity Prompts for Text-to-Speech and Style Captioning[J]. arXiv preprint arXiv:2406.07969v1, 2024.

允许进入毕业设计（论文）下一阶段：是 ☑ 否 ☐		指导教师	
日期	2025 年 12 月 26 日	签字	