北京邮电大学人工智能学院

本科毕业设计（论文）中期进展情况检查表

<table>
<tr><td>学院</td><td colspan="2">人工智能学院</td><td>专业</td><td colspan="2">人工智能</td></tr>
<tr><td>学生姓名</td><td>邓圣曦</td><td>学号</td><td>2022212222</td><td>班级</td><td>2022219112</td></tr>
<tr><td>指导教师姓名</td><td>刘刚</td><td>所在单位</td><td>北京邮电大学电子工程学院</td><td>职称</td><td>副教授</td></tr>
<tr><td rowspan="2">设计（论文）题目</td><td colspan="5">（中文）基于文本描述的零样本语音合成研究</td></tr>
<tr><td colspan="5">（英文）Research on Text-Description-Based Zero-Shot Speech Synthesis</td></tr>
<tr><td>目前已完成任务</td><td colspan="5">
近年来，随着生成式人工智能的爆发，智能语音合成（TTS）技术正经历着从清晰度向高表现力、高可控性和零样本克隆的变革。现有的主流零样本 TTS 模型已经展现出了极强的泛化能力，通常依赖几秒钟的真实参考音频作为声学提示即可模仿生成音频。但在实际的创意内容生产（如有声小说、游戏 NPC 配音等）中，用户往往需要构建虚拟的全新角色，寻找符合人设的参考录音不仅困难，还容易引发版权争议。为解决上述痛点，本课题致力于探索如何将自然语言的语义描述映射到 TTS 模型的声纹空间。目前项目已基本确立了“文本描述驱动音色生成”的核心方案，通过大语言模型理解文本语义并结合跨模态适配器（Adapter），成功实现了无需参考音频、仅凭文字描述即可生成对应声学特征向量的流程，打通了从文本到个性化语音生成的链路。
截至中期检查，已经完成了开题报告中内容一‘成熟零样本语音合成系统复现’，以及内容二‘显性文本描述到隐性声学特征的映射适配器设计与实现’。包括基座复现、结构分析、适配器设计、数据集构建与训练验证等细分步骤，具体如下：
1. 调研语音合成发展现状，基座选取：
在课题前期，系统调研了零样本语音合成的发展脉络，阅读了 VALL-E、PromptTTS、NaturalSpeech 等相关工作论文，确立了本课题的基本研究思路：现有零样本 TTS 系统虽然具体实现不同，但大多会从参考音频中提取某种能够表征说话人身份、音色特征或风格属性的连续条件表示，作为后续生成过程的关键控制表征。
基于这一认识，将本课题的核心问题理解为：在不依赖参考音频的前提下，能否通过解析自然语言文本描述中的音色语义，生成与原有说话人嵌入空间兼容的连续向量，从而替代参考音频提供的说话人身份表征。就方法本质而言，这属于一个从文本语义空间到说话人声纹嵌入空间的跨模态映射与对齐问题。
PromptTTS 等基于自然语言提示的语音生成研究已经证明，文本描述可以被编码为控制语音风格或说话人特征的条件表示。通过使用 BERT 类编码器从 style prompt 中提取全局风格表征，结合线性层或混合密度网络，将自然语言描述映射到声学模型所使用的 speaker/style embedding 空间。这些工作都说明，“自然语言语义 → 声音模态表征”的跨模态映射在理论上和经验上都是可行的。
随后完成了 ChatTTS 的环境部署，分析结构得知其用一个 768 维的 spk_emb
</td></tr>
</table>

向量来表征音色，于是基于 ESD 数据集对 ChatTTS 进行了测试。测试其在有参考音频的情况下，对参考音频的音色捕捉还原能力以及潜空间聚类可解释性等指标。结果显示，最基础的零样本音色克隆获得的说话人相似度也仅 0.64，对于不同类别的声音嵌入聚类效果也不佳，难以稳定支撑后续的映射任务。于是在进一步调研之后，选择了 CosyVoice 3 作为新的基座模型。测试集相同的情况下，CosyVoice 3 的零样本音色克隆说话人相似度达到了 0.9+，其参考音频经 CAM++说话人识别器提取后的 192 维音色向量具有清晰的聚类边界与更好的身份分离效果，同时系统本身已经具备较成熟的自然语言韵律控制能力。

就具体的聚类结果而言，CosyVoice3 的 speaker embedding 在 ESD 数据集上表现出明显优于 ChatTTS 的说话人可分性。其说话人轮廓系数由 ChatTTS 的-0.1020 提升至 0.1688，说明同一说话人的样本在 CosyVoice3 的嵌入空间中更加集中、不同说话人之间的边界也更清晰；同时，K-Means 聚类中，标识标签情况与真实情况一致性的指标 ARI 由 0.0221 大幅提升至 0.8038，表明 CosyVoice3 的聚类结果已经能够较好地恢复真实的说话人结构；此外，类内/类间距离比从 0.8838 降低到 0.5521，进一步说明其具有更强的类内紧致性与类间分离性。

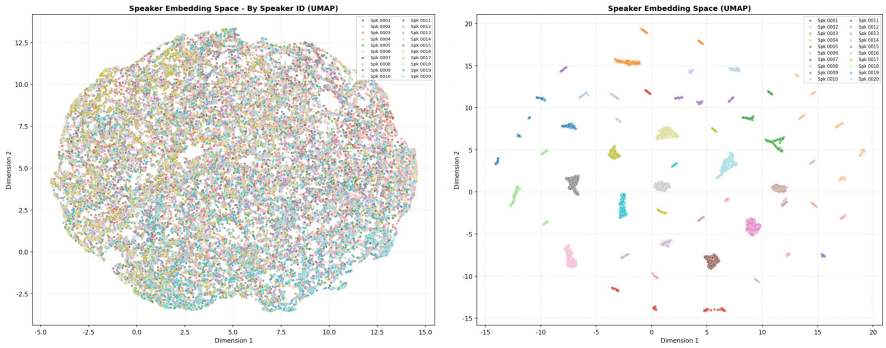

(a)ChatTTS 聚类分析结果　　(b) CosyVoice 3 聚类分析结果

图 1：说话人嵌入向量的聚类分析结果

2. 分析基座模型原理，明确实现思路：

CosyVoice 3 并非将文本直接映射为语音波形，而是由文本/指令条件编码、speech token 语言模型、条件流匹配声学模型以及 HiFT 声码器组成的分层生成框架。参考音频被提取为多类条件信息：分支一，由 CAM++说话人识别器提取的 192 维 speaker embedding，作为 Flow 模块的全局说话人条件；分支二，利用 speech tokenizer 提取离散 speech token，作为 Flow 模块的语音提示 token；分支三，将参考音频转换为 mel 级 prompt feature，作为 Flow 模块的局部声学提示。随后，语言模型依据“指令文本+待合成文本”自回归生成目标 speech token 序列；Flow 模块再参考 speech token、speaker embedding 与 prompt mel 特征恢复目标梅尔频谱，最后由 HiFT 声码器合成为最终波形。

该结构表明，CosyVoice3 中“说话人身份控制”存在一条显式且相对独立的建模路径，即“参考音频→CAM++→speaker embedding→Flow 全局说话人条件”。相较之下，其余参考语音分支更多承担生成提示、韵律约束与局部声学补充作用。特别是在 instruct 模式下，韵律控制已经由自然语言指令控制，分支二不被启用。同时，分支三提供的提示特征在结构上也具备被置空的条件。因此，从体系结构角度看，将 speaker embedding 分支作为替换对象是可行的。

基于上述分析，为实现课题目标，并不需要对 CosyVoice3 的整体生成主干进行重构，而是在保留其 speech token 生成能力与现有声学建模框架的前提下，定点替换“参考音频 → CAM++ → speaker embedding”这一身份分支，使系统的音色指定方式由“依赖参考音频提取说话人表示”转变为“依赖自然语言描述生成说话人表示”。

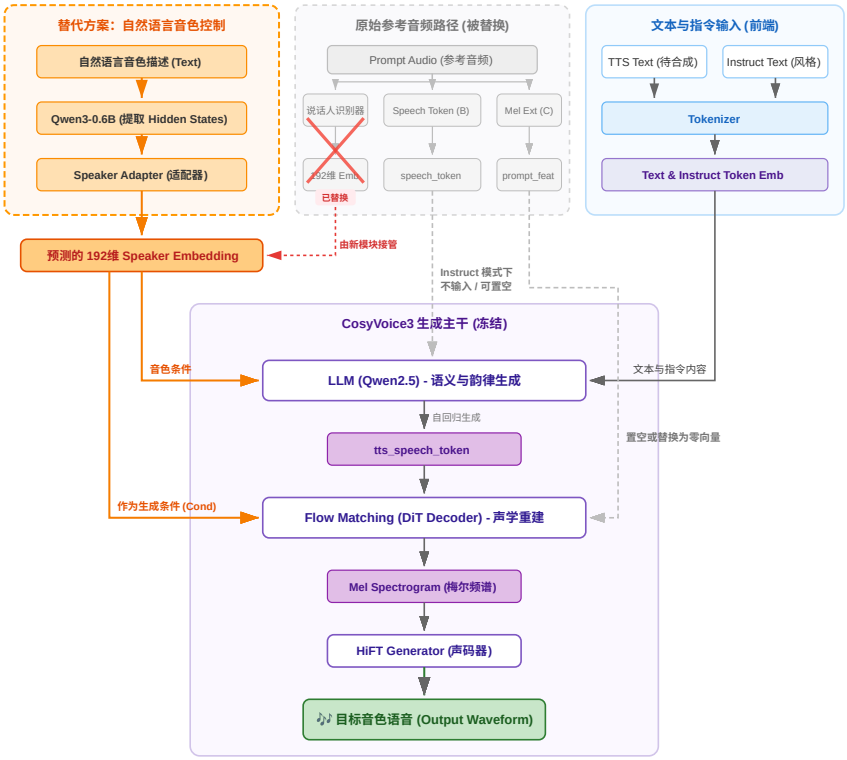

图 2：CosyVoice 3 模型结构示意图及替换部分

3. 跨模态映射设计与数据集构建：

此前这类工作存在着一些比较明显的局限：一方面，它们大多依赖 BERT 式小模型和预定义标签体系，先将描述压缩为有限类别或低维全局表征，再映射到说话人向量，存在明显的信息损失；另一方面，这种做法本质上仍偏向分类范式，对开放措辞、自由改写等描述的泛化能力有限。基于此，改用生成范式的思路，将完整的自然语言音色描述输入 Qwen3-0.6B，提取最后一层 1024 维高层 hidden states，以尽可能保留文本中的细粒度语义信息；后接轻量 Cross-Attention Adapter，将高维语义聚合并映射到 CosyVoice 3 所需的 192 维 CAM++连续说话人向量空间。Qwen3 负责语义理解，Adapter 负责模态对齐，从而实现“语义理解”与“声纹空间映射”的解耦。同时保持大模型本体权重不变，避免在小规模数据集上整体微调大模型所带来的灾难性遗忘问题。

为了支撑训练 Adapter 建立映射，构建了与之配套的数据集：先以性别、年龄、音调、清晰度、厚重度五个维度构造结构化语义骨架，得到 288 条标签化模板，再通过大模型改写将其扩展为多样化的(288*4=1152 条)自然语言描述，随后利用可控语音合成系统批量生成对应音频，提取其 192 维 CAM++向量，形成约 2.3

万条“自然语言描述 - speaker embedding”的监督对。通过这种方式，训练样本的输入侧保持为开放形式的自然语言，监督侧则锚定在 CosyVoice 3 已经验证有效的 speaker embedding 空间中，从而为适配器学习稳定、可泛化的跨模态映射关系提供了数据基础。

4. 设计损失函数并训练：

为了使适配器既能准确回归目标 speaker embedding，又能学到描述间的结构关系，设计了联合损失函数：主损失采用均方误差与余弦相似度之和，直接约束模型预测的 192 维向量在数值和方向上都接近目标 CAM++向量；在此基础上，加入 InfoNCE 对比损失，将由同一描述或同一语义组的自然语言改写得到的样本视为正样本，将不同描述视为负样本，以增强模型对自然语言变体的鲁棒性和嵌入空间的可分性；此外，在 192 维输出向量上额外接入性别和年龄两个分类辅助头，并引入交叉熵损失作为结构化约束，使模型在学习细粒度音色语义映射的同时，不偏离基本生理属性边界。训练实现方面，设计了分组采样策略，使原本同属一组的样本更容易在同一 batch 中出现，以发挥对比损失作用；同时配合 warmup、梯度裁剪、checkpoint 管理和 TensorBoard 日志记录等训练机制，保证优化过程稳定可控。训练曲线表现出较平稳的收敛趋势，说明从文本语义到 speaker embedding 的监督学习链路已经成功打通。

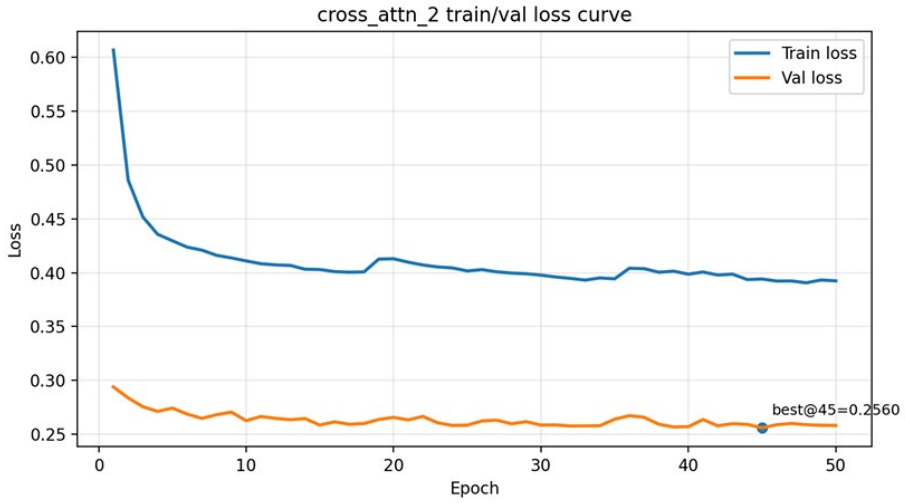

图 3：适配器训练过程损失变化情况

5. 适配器性能评估与阶段性结果：

评估围绕数据集构建时设定的五个语音描述维度展开。评估采用控制变量方式生成测试样本，每次仅改变单一目标维度，并使用统一描述文本进行多次重复采样。在指标设计上，主要从身份层和声学层两个方面进行分析：身份层使用 CAM++提取合成语音的说话人 embedding，并统计同一描述组内的平均相似度与不同描述组之间的平均相似度，以考察模型生成结果的组内稳定性和组间可分性；声学层则提取基频均值（F0）、能量均值、频谱重心、频谱带宽和频谱滚降五项声学特征，并对不同描述组之间的差异分别计算 p 值、η^2 和 effect_size，用于判断差异是否显著以及差异强度的大小。通过上述指标，可以较为直观地评估生成的说话人向量是否能够在 CosyVoice 3 中形成可感知、可区分的属性控制效果。实际结果显示，大部分维度下，系统现已成功具备了根据自然语言描述创造个性化音色的能力。

维度	随机对照 CAM++组间/组内相似度	随机对照声学结果	随机结论
gender	0.933 / 0.733	无显著项；	区分度不足
age	0.921 / 0.772	无显著项；	区分度不足
pitch	0.955 / 0.831	无显著项；	区分度不足
clarity	0.940 / 0.787	能量均值：p=0.011，η^2=0.524，effect_size=0.214	声学层有效
thicknes s	0.951 / 0.825	无显著项；	区分度不足
	训练后 CAM++组间/组内相似度	训练后声学结果	训练后结论
gender	0.583 / 0.898	能量均值：p=0.002，η^2 =0.433，effect_size=1.658；	双层有效
age	0.729 / 0.903	频谱带宽 p=0.009，η^2 =0.334，effect_size=0.276；	双层有效
pitch	0.819 / 0.872	能量均值：p=0.003，η^2 =0.293，effect_size=0.549	声学层有效
clarity	0.769 / 0.878	能量均值：p=0.003，η^2 =0.364，effect_size=1.435	双层有效
thicknes s	0.914 / 0.893	无显著项；最高趋势为 energy_mean：p=0.064	区分度不足

表 1：个性化音色可区分度情况对比。存在多个显著声学指标时，表中列出最显著项

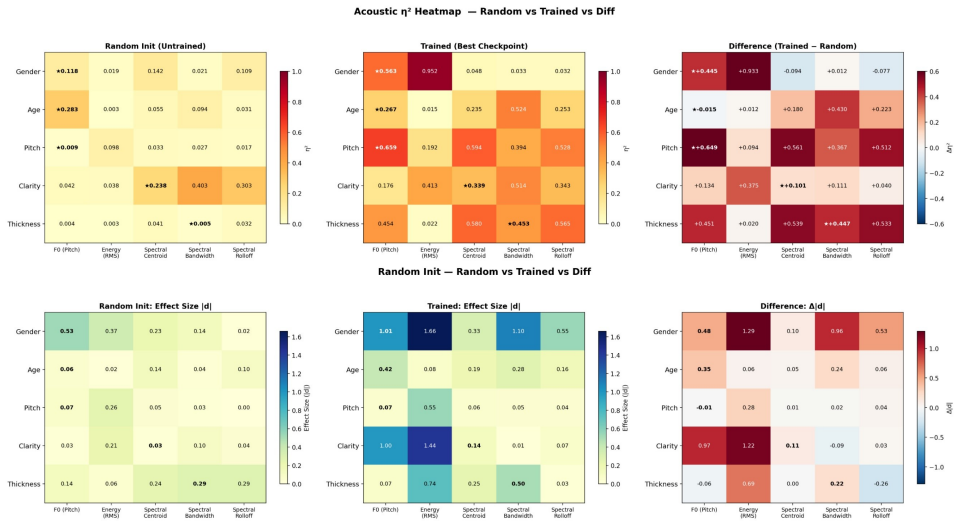

图 4：消融实验 随机初始化 vs 训练后 Adapter 各声学指标 p 值三联对比图

是否符合任务书要求进度　　是 ☑　　否 ☐

尚需完成的任

1. 多角色有声小说自动生成演示系统的集成与开发： 将现阶段已验证成功的模块进行实际应用，完成课题“任务内容三”的系统搭建。计划集成长文本解析模块，实现角色属性与动态情感的自动追踪，并利用其生成的动态文本描述流实时驱动适配器和 CosyVoice 3 基座模型。最终通过前端框架（如 Gradio 或 Vue）封装，构建一个具备剧本解析、角色特征预览及音频合成播放功能的完整可视化演示系统。

2. 系统的综合性能评估与推理效率优化： 在演示系统集成完毕后，开展性能测评。主观方面将组织小规模的 MOS 测试评估合成语音的自然度与提示一致性；客观方面将使用 InstructTTSEval 等基准测试系统验证提示指令的遵循精度。同时，针对自回归模型逐 token 生成造成的 GPU 利用率不足的瓶颈，探索推理流程的并行化策略以优化生成速度。

3. 毕业论文撰写与答辩准备： 全面汇总、整理项目全过程的研究成果，对各项

<table>
<tr><td rowspan="2">务</td><td colspan="3">实验数据进行图表化处理，完成毕业设计论文的系统撰写与规范排版。按进度提交论文进行内审与查重检测，并根据反馈意见定稿。最终制作答辩 PPT、准备演示系统视频或现场演示环境，迎接毕业设计答辩。</td></tr>
<tr><td colspan="3">是否可以按期完成设计（论文） ☑是 □否</td></tr>
<tr><td rowspan="2">存在问题和解决办法</td><td>存在问题</td><td colspan="2">1.部分预设语义维度的特征映射与训练尚不充分。个别语义维度的生成效果未达预期。例如，“厚重度”维度的特征在客观声学物理量指标上的区分度尚显不足；“老年”音色的实际生成听感也不够自然。这表明适配器模型对这类复杂、非结构化的自然语言描述的深层映射还存在欠缺。
2.当前训练集的音色覆盖度有限，系统泛化边界亟待拓宽。 前期构建训练集时，主要局限于性别、年龄、音调、清晰度、厚重度这 5 个基础的结构化维度体系。这导致大量处于常规描述范围之外的特殊音色（如赛博电子音、特定非标准人声等）在训练集中处于空白状态，限制了模型在开放域下处理无限制自由文本的表现能力。</td></tr>
<tr><td>拟采取的办法</td><td colspan="2">1.微调联合损失函数与定向扩充困难样本：针对局部特征映射不充分的问题，计划深入微调适配器联合损失函数的权重分配。同时，定向扩充特定类别的样本的对齐数据，以提升适配器对复杂组合自然语言描述特征映射的精准度。
2.结合大模型进行自由文本标注扩增，提升开放域泛化能力：为了打破预设维度的局限，后续计划引入更多具有多样性的真实音频资源，并结合多模态大语言模型进行自由文本标注扩增。以此拓宽适配器的语义-声纹泛化边界，使其具备更强的应对广阔、不受限的开放式自然语言音色描述及创造能力。</td></tr>
<tr><td>指导教师签字</td><td></td><td>日期</td><td>年 月 日</td></tr>
<tr><td>检查小组评分及意见</td><td colspan="3">评分： （总分：30 分 ）

组长签字： 年 月 日</td></tr>
</table>